DOCUMENTACIÓN TÉCNICA Y CASO DE ESTUDIO

Diseño e Implementación de un Data Mart para la Asignación Óptima de Recursos y Prevención de Siniestralidad Vial

Solución End-to-End de Business Intelligence aplicada al Municipio de La Paz-Bolivia

Stack Tecnológico: PostgreSQL • Pentaho Data Integration (ETL) • SQL • Power BI • DAX

Metodología: HEFESTO (Data Warehousing & BI)

Elaborado por:

Miguel Matheus Quispe Chipana

Data Analyst & BI Developer

Fecha: 2026 | **La Paz, Bolivia**

ÍNDICE GENERAL

1 INTRODUCCIÓN
- 1.1 Objetivo del proyecto
- 1.1.1 Objetivo General
- 1.1.2 Objetivos Específicos
- 1.2 Alcance y limitaciones
- 1.2.1 Alcances
- 1.2.2 Límites
- 1.3 Metodología HEFESTO aplicada
- 1.4 Herramientas y Tecnologías Utilizadas

2 FASE DE INICIO
- 2.1 Identificación de la problemática de negocio
- 2.2 Definición de objetivos estratégicos e informacionales
- 2.2.1 Objetivos estratégicos
- 2.2.2 Objetivos informacionales
- 2.3 Stakeholders y roles en el proyecto
- 2.4 Planificación y cronograma general

3 FASE DE ANÁLISIS
- 3.1 Análisis de la empresa / institución
- 3.1.1 Misión
- 3.1.2 Visión
- 3.1.3 Organigrama
- 3.1.4 Procesos de negocio principales
- 3.1.5 Áreas o departamentos clave
- 3.1.6 Necesidades de información actuales
- 3.2 Identificación y análisis de fuentes de datos
- 3.3 Requerimientos de información del negocio
- 3.4 Definición de KPIs y métricas clave
- 3.5 Modelo conceptual del Data Mart
- 3.5.1 Entidades de negocio
- 3.5.2 Relaciones de alto nivel
- 3.5.3 Hechos e Indicadores

4 FASE DE DISEÑO
- 4.1 Modelo conceptual aumentado
- 4.1.1 Definición de hechos y dimensiones
- 4.1.2 Granularidad y jerarquías
- 4.1.3 Esquema dimensional preliminar
- 4.2 Modelo lógico del Data Warehouse
- 4.2.1 Tablas de dimensiones
- 4.2.2 Tablas de hechos
- 4.2.3 Claves primarias y foráneas

4.2.4 Atributos y cardinalidades
4.3 Diseño de la arquitectura del Data Warehouse (Star Schema)
4.4 Definición de procesos ETL
5 FASE DE CONSTRUCCIÓN
5.1 Implementación del Data Warehouse con Pentaho
5.1.1 Instalación y configuración de Pentaho Data Integration (PDI)
5.1.2 Extracción de datos desde las fuentes
5.1.3 Transformación y limpieza de datos
5.1.4 Carga en el Data Warehouse (ETL completo)
5.2 Creación de Dashboards con Power BI
5.2.1 Conexión de Power BI con el Data Warehouse
5.2.2 Modelado de datos en Power BI
5.2.3 Creación de visualizaciones y reportes
5.2.4 Publicación y despliegue de dashboards
6 FASE DE IMPLANTACIÓN
6.1 Validación de datos y consistencia
6.2 Pruebas de rendimiento
6.3 Verificación de KPIs y métricas
6.4 Implementación en el entorno de producción
6.5 Documentación del proceso ETL y del modelo de datos
6.6 Manual de usuario para Power BI
7 FASE DE EVALUACIÓN
7.1 Resultados obtenidos
7.2 Lecciones aprendidas
7.3 Futuras mejoras y optimización
8 CONCLUSIONES Y RECOMENDACIONES

1 INTRODUCCIÓN

La siniestralidad vial constituye un fenómeno que puede ser analizado desde múltiples dimensiones: temporal, territorial, vehicular, humana y ambiental. Para una gestión orientada a la prevención y a la utilización eficiente de recursos, no basta con disponer de registros individuales; es necesario convertirlos en información consolidada que permita identificar concentraciones, patrones y comportamientos.

El presente proyecto propone el diseño de un Data Mart orientado a la asignación óptima de recursos y la prevención de la siniestralidad vial en el Municipio de La Paz, utilizando como fuente el Sistema Integrado de Siniestralidad y Movilidad. La solución se estructura mediante un modelo dimensional compuesto por una tabla de hechos, denominada fact_siniestralidad, y las dimensiones dim_tiempo, dim_ubicacion, dim_vehiculo, dim_perfil_involucrado y dim_entorno.

El análisis se orienta a responder requerimientos de nivel estratégico, operacional y regulatorio. Entre ellos se encuentran la priorización de inversión en infraestructura vial, la medición del retorno de obras, la optimización de operativos de alcoholemia, la identificación de condiciones asociadas a traslados médicos, la focalización de campañas de prevención y el análisis de vehículos según antigüedad y estado.

La construcción de la solución seguirá la metodología HEFESTO y utilizará PostgreSQL para la gestión de datos, Pentaho Data Integration para los procesos ETL y Power BI para el modelado analítico y la construcción de dashboards. El resultado esperado es disponer de información multidimensional que sirva como apoyo para el análisis y la planificación, sin sustituir la decisión de las autoridades responsables.

1.1 Objetivo del proyecto

1.1.1 Objetivo General

Diseñar un Data Mart para la asignación óptima de recursos y prevención de la siniestralidad vial en el Municipio de La Paz, mediante la integración y análisis multidimensional de información proveniente del Sistema Integrado de Siniestralidad y Movilidad, aplicando la metodología HEFESTO y herramientas de Business Intelligence.

1.1.2 Objetivos Específicos

1. Analizar la estructura y disponibilidad de información del Sistema Integrado de Siniestralidad y Movilidad.
2. Identificar las necesidades de información asociadas a la gestión estratégica, operacional y regulatoria de la siniestralidad vial.
3. Definir las dimensiones y medidas necesarias para analizar tiempo, ubicación, vehículo, perfil del involucrado y condiciones del entorno.
4. Definir indicadores que permitan responder los siete requerimientos de información establecidos para el proyecto.
5. Diseñar el modelo conceptual y dimensional utilizando fact_siniestralidad como hecho central.
6. Implementar el Data Mart en PostgreSQL respetando el modelo definido.
7. Implementar procesos ETL mediante Pentaho Data Integration para extracción, transformación y carga.
8. Construir dashboards en Power BI para representar los indicadores y perspectivas definidas.
9. Validar la consistencia de la información entre las fuentes y el Data Mart.
10. Proporcionar información analítica que sirva como apoyo para la planificación preventiva y la asignación de recursos.

1.2 Alcance y limitaciones

1.2.1 Alcances

- Analizar información relacionada con siniestralidad vial en el Municipio de La Paz.
- Utilizar el Sistema Integrado de Siniestralidad y Movilidad como fuente principal de información.
- Trabajar con las dimensiones dim_tiempo, dim_ubicacion, dim_vehiculo, dim_perfil_involucrado y dim_entorno.
- Utilizar fact_siniestralidad como tabla de hechos central.
- Implementar indicadores asociados a los siete requerimientos definidos.
- Construir procesos de extracción, transformación y carga mediante Pentaho.
- Implementar el Data Mart en PostgreSQL.
- Desarrollar visualizaciones y dashboards en Power BI.
- Realizar validaciones de consistencia y correspondencia de datos.

1.2.2 Límites

- El proyecto se limita al ámbito de análisis definido para el Municipio de La Paz.
- El Data Mart tiene finalidad analítica y no reemplaza al sistema transaccional.
- Los resultados dependen de la calidad, completitud y disponibilidad de los datos de origen.
- El sistema no realiza automáticamente la asignación física o administrativa de recursos; proporciona información para apoyar dicha decisión.
- El análisis no implica por sí mismo causalidad entre las variables observadas.
- Los requerimientos se implementarán con los atributos disponibles en el modelo definido, sin agregar nuevas dimensiones al modelo conceptual presentado.

1.3 Metodología HEFESTO aplicada

La metodología HEFESTO organiza el desarrollo de soluciones de Business Intelligence en fases sucesivas que permiten pasar de las necesidades del negocio a un modelo dimensional implementable. En este proyecto se consideran las fases de Inicio, Análisis, Diseño, Construcción, Implantación y Evaluación.

La Fase de Inicio establece la problemática, objetivos y actores; la Fase de Análisis identifica fuentes, requerimientos, indicadores y modelo conceptual; la Fase de Diseño define el modelo dimensional; la Fase de Construcción implementa ETL y dashboards; la Fase de Implantación valida la solución; y la Fase de Evaluación analiza resultados, lecciones aprendidas y mejoras.

1.4 Herramientas y Tecnologías Utilizadas

Herramienta / tecnología	Utilización en el proyecto
PostgreSQL	Gestión del entorno de datos y del Data Mart.
pgAdmin 4	Administración, consultas y validación de PostgreSQL.
Pentaho Data Integration (PDI)	Extracción, transformación y carga de datos mediante procesos ETL.
Power BI	Modelado analítico, medidas DAX, visualizaciones y dashboards.
SQL	Consulta, transformación y validación de información.
DAX	Cálculo de medidas analíticas requeridas en Power BI.

2 FASE DE INICIO

La Fase de Inicio establece el contexto del proyecto, la problemática de negocio, los objetivos estratégicos e informacionales, los actores involucrados y la planificación general. Esta fase permite definir qué problema se pretende resolver mediante la solución de Business Intelligence y qué información deberá estar disponible para los usuarios.

2.1 Identificación de la problemática de negocio

La gestión de la siniestralidad vial requiere analizar simultáneamente información sobre cuándo y dónde ocurren los hechos, qué condiciones ambientales y de infraestructura se presentan, qué vehículos intervienen, qué características tienen las personas involucradas y qué consecuencias se registran.

Cuando esta información se encuentra distribuida en estructuras operacionales, las consultas orientadas a decisiones estratégicas y operativas pueden requerir múltiples combinaciones de datos. Esto dificulta obtener rápidamente respuestas como cuáles son los puntos donde coinciden condiciones de infraestructura desfavorables y mayor severidad, qué períodos muestran cambios después de una intervención, o qué combinaciones de día, hora y sobriedad concentran incidentes.

La problemática que aborda el proyecto consiste, por tanto, en transformar los registros de siniestralidad en información multidimensional que pueda ser consultada mediante

indicadores y perspectivas homogéneas. El Data Mart permitirá organizar el análisis alrededor del hecho central fact_siniestralidad y sus cinco dimensiones.

- Necesidad de priorizar puntos de infraestructura vial según indicadores históricos de severidad.
- Necesidad de comparar el comportamiento de siniestros antes y después de intervenciones.
- Necesidad de identificar días y bloques horarios relacionados con estado de sobriedad alterado.
- Necesidad de analizar condiciones climáticas y de vía asociadas a traslados médicos.
- Necesidad de identificar perfiles demográficos asociados a accidentes con heridos graves.
- Necesidad de analizar la participación de vehículos antiguos y su condición de seguro.
- Necesidad de comparar la accidentabilidad asociada al estado del vehículo.

2.2 Definición de objetivos estratégicos e informacionales

2.2.1 Objetivos estratégicos

1. Proporcionar información multidimensional para apoyar la priorización de inversión en infraestructura vial.

2. Facilitar la evaluación de variaciones interanuales de siniestros graves en contextos donde se hayan ejecutado obras.

3. Apoyar la planificación de operativos de control mediante el análisis de tiempo, ubicación y sobriedad.

4. Proporcionar información para anticipar y analizar concentraciones de traslados médicos.

5. Apoyar la focalización de campañas de prevención según perfil de las personas involucradas.

6. Generar evidencia analítica para estudiar el comportamiento de vehículos según antigüedad, seguro y estado.

7. Facilitar indicadores que puedan ser utilizados en procesos regulatorios y de auditoría.

8. Consolidar la información en una plataforma de Business Intelligence mediante Power BI.

2.2.2 Objetivos informacionales

Los objetivos informacionales se derivan directamente de los siete requerimientos establecidos para el proyecto:

- Identificar los cinco macrodistritos y calles específicas con mayor Índice de Severidad Histórico bajo condiciones de iluminación deficiente y estado de vía malo.
- Medir la variación porcentual interanual de siniestros graves en intersecciones donde se ejecutaron obras públicas.
- Identificar días de la semana y bloques horarios con concentración de conductores con sobriedad alterada que derivan en colisiones múltiples.
- Determinar condiciones climáticas asociadas con incrementos de traslados médicos en vías de alta velocidad.
- Identificar perfiles de edad y género que concentran mayor porcentaje de responsabilidad en accidentes con heridos graves.
- Determinar qué porcentaje de fatalidades corresponde al 20% del parque automotor más antiguo y sin seguro SOAT vigente.
- Comparar la accidentabilidad por mal estado del vehículo con el promedio general y la desviación estándar considerada.

2.3 Stakeholders y roles en el proyecto

Los stakeholders se definen a partir de los usuarios descritos en los requerimientos. Sus roles representan el uso esperado de la información dentro del contexto del proyecto.

Stakeholder	Nivel	Necesidad principal
Director de Infraestructura Vial	Estratégico	Priorización de inversión en infraestructura vial.

Director de Proyectos y Programas	Estratégico	Evaluación del comportamiento de siniestros después de obras.
Director de Control de la Circulación	Operacional	Planificación de operativos de alcoholemia.
Director de Información y Estadística	Operacional	Análisis de información de riesgo y traslados médicos.
Director de Seguridad Vial	Operacional / Regulatorio	Prevención y focalización de campañas.
Director de Tránsito y Transporte	Regulatorio	Análisis de vehículos y apoyo a decisiones regulatorias.
Equipo técnico BI / Datos	Transversal	ETL, modelado, indicadores, validación y dashboards.

2.4 Planificación y cronograma general

La planificación se organiza de acuerdo con las fases de HEFESTO y contempla las actividades necesarias para pasar de la identificación de requerimientos a la implementación y evaluación.

Fase	Actividades principales	Entregable
Inicio	Problemática, objetivos, stakeholders y planificación.	Definición del proyecto.
Análisis	Fuentes, requerimientos, KPIs y modelo conceptual.	Especificación analítica.

Diseño	Dimensiones, hechos, granularidad y esquema dimensional.	Diseño del Data Mart.
Construcción	ETL, carga y dashboards.	Data Mart y Power BI.
Implantación	Validación, pruebas y documentación.	Solución validada.
Evaluación	Resultados, lecciones y mejoras.	Evaluación final.

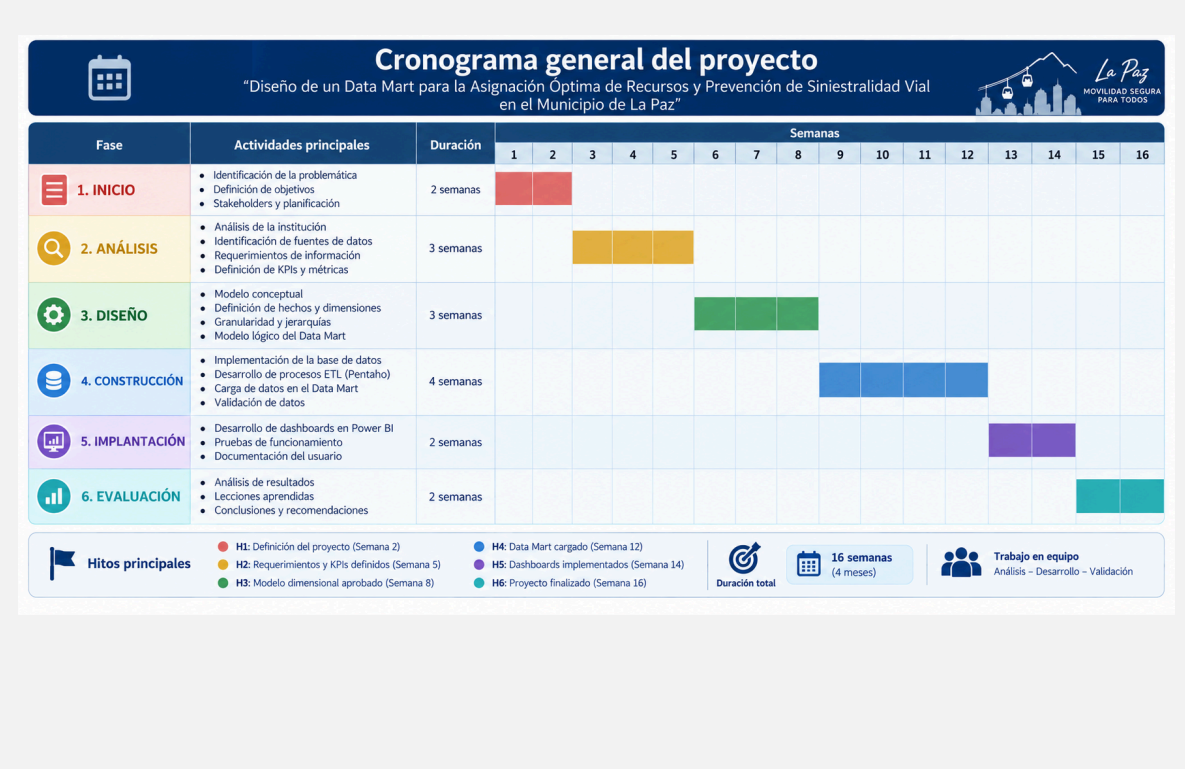

3 FASE DE ANÁLISIS

La Fase de Análisis traduce las necesidades del negocio en requerimientos de información, indicadores y perspectivas. En esta etapa se estudia el contexto institucional, las fuentes de datos y, finalmente, el modelo conceptual que será utilizado en la fase de diseño.

3.1 Análisis de la empresa / institución

El proyecto se desarrolla en el contexto del Municipio de La Paz y aborda la siniestralidad vial como fenómeno de análisis para la planificación de recursos, prevención y gestión. El alcance institucional se concentra en los actores y procesos relacionados con infraestructura vial, movilidad, seguridad vial, control de circulación, información estadística y tránsito y transporte.

3.1.1 Misión

Para efectos del proyecto, la misión se aborda desde la necesidad de disponer de información que apoye la gestión municipal vinculada con movilidad, seguridad vial, infraestructura y atención de necesidades urbanas. Esta formulación se utiliza como contexto del proyecto y no pretende sustituir una declaración institucional oficial.

3.1.2 Visión

Desde la perspectiva del proyecto, se plantea una gestión apoyada en información analítica capaz de identificar patrones de siniestralidad y apoyar la planificación preventiva, la evaluación de intervenciones y el análisis de riesgos.

3.1.3 Organigrama

El organigrama que se incorpore deberá representar las áreas y cargos directamente relacionados con los siete requerimientos del proyecto, manteniendo como referencia los roles indicados en el documento de requerimientos.

3.1.4 Procesos de negocio principales

1. Registro de siniestralidad vial.
2. Registro de fecha, hora y características temporales del hecho.
3. Registro de ubicación y características del entorno.
4. Registro de vehículos involucrados.

5. Registro del perfil de las personas involucradas.

6. Registro de condiciones de sobriedad y grado de alcohol medido cuando corresponde.

7. Registro de consecuencias humanas como fallecimiento o heridas graves.

8. Registro de información relacionada con traslados médicos.

9. Consolidación y análisis histórico de siniestralidad.

10. Planificación y evaluación de intervenciones preventivas.

11. Generación de indicadores para decisiones estratégicas, operacionales y regulatorias.

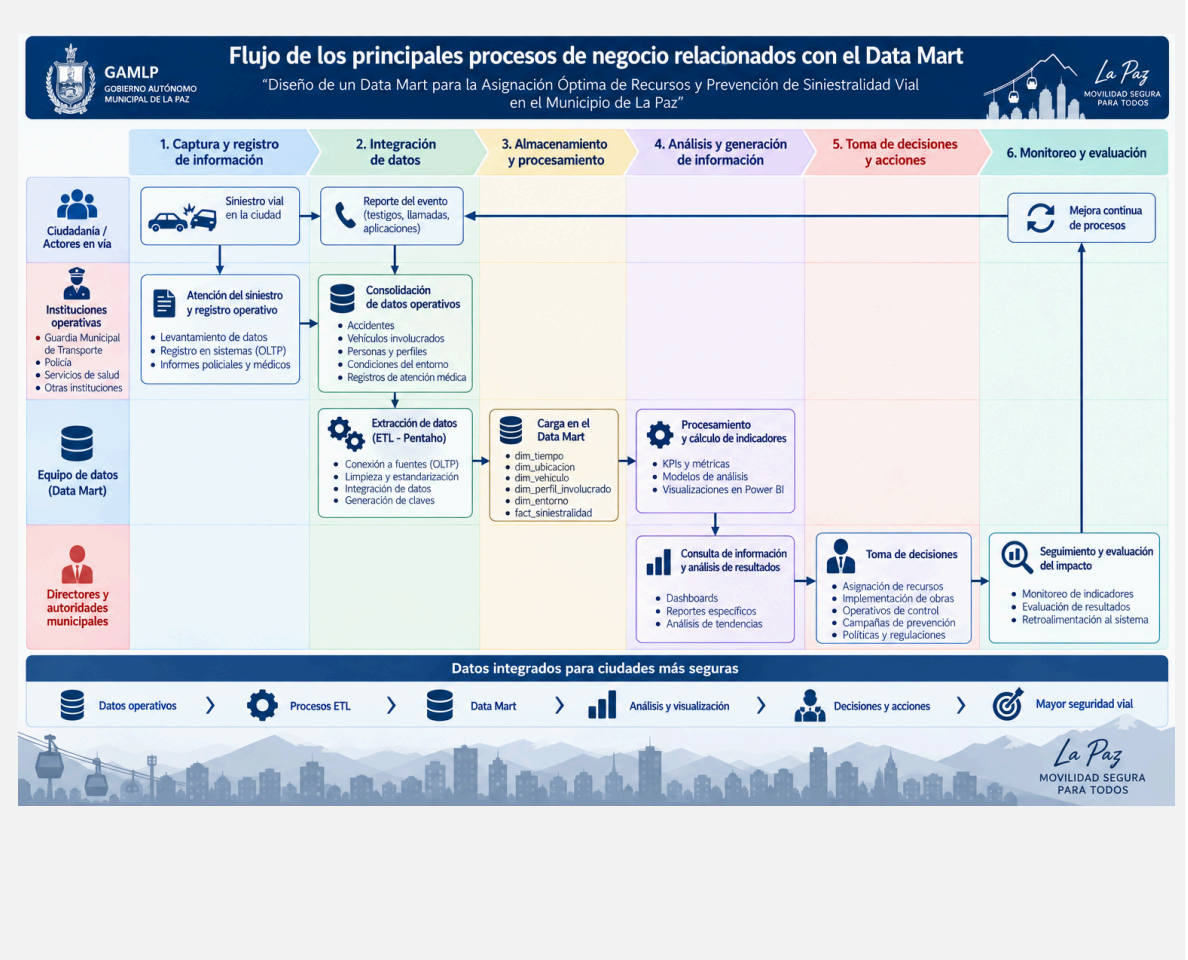

3.1.5 Áreas o departamentos clave

- Secretaría Municipal de Infraestructura Pública / Dirección de Infraestructura Vial.
- Secretaría Municipal de Planificación para el Desarrollo / Dirección de Proyectos y Programas.
- Secretaría Municipal de Movilidad y Seguridad Ciudadana / Dirección de Control de la Circulación.
- Dirección de Información y Estadística.
- Dirección de Seguridad Vial.
- Dirección de Tránsito y Transporte.

- Equipo técnico de datos, bases de datos y Business Intelligence.

3.1.6 Necesidades de información actuales

- Priorización territorial de inversión en infraestructura vial.
- Evaluación del comportamiento de siniestros después de obras.
- Identificación de horarios y días críticos para operativos.
- Análisis de condiciones ambientales y de vía asociadas a traslados.
- Segmentación de perfiles de riesgo para campañas.
- Análisis de antigüedad y condiciones de los vehículos.
- Identificación de comportamientos que superan referencias de accidentabilidad.

3.2 Identificación y análisis de fuentes de datos

La fuente principal del proyecto es el Sistema Integrado de Siniestralidad y Movilidad. El modelo analítico que se utilizará está conformado por fact_siniestralidad y las dimensiones dim_tiempo, dim_ubicacion, dim_vehiculo, dim_perfil_involucrado y dim_entorno.

La siguiente descripción se limita al modelo proporcionado para el proyecto. No se incorporan nuevas dimensiones de tipo de accidente, causa o gravedad, ya que el modelo definido para la solución no contempla dichas tablas.

Elemento	Tipo	Información visible / función
fact_siniestralidad	Tabla de hechos	Cantidad de involucrados, fallecidos, heridos graves, género asociado a traslado médico, grado de alcohol, claves de dimensiones y otros atributos.
dim_tiempo	Dimensión	Año, bloque horario, fin de semana, fecha limpia, hora limpia, mes, nombre del día y número del día de semana.
dim_ubicacion	Dimensión	Barrio/zona, calle principal, macrodistrito y clave de ubicación.
dim_vehiculo	Dimensión	Aseguradora SOAT, estado del vehículo, marca, rango de antigüedad, tipo y clave de vehículo.
dim_perfil_involucrado	Dimensión	Edad calculada, estado de sobriedad, género, lesión aparente, rango de edad, rol involucrado y clave de perfil.
dim_entorno	Dimensión	Clima, estado de vía, iluminación y clave de entorno.

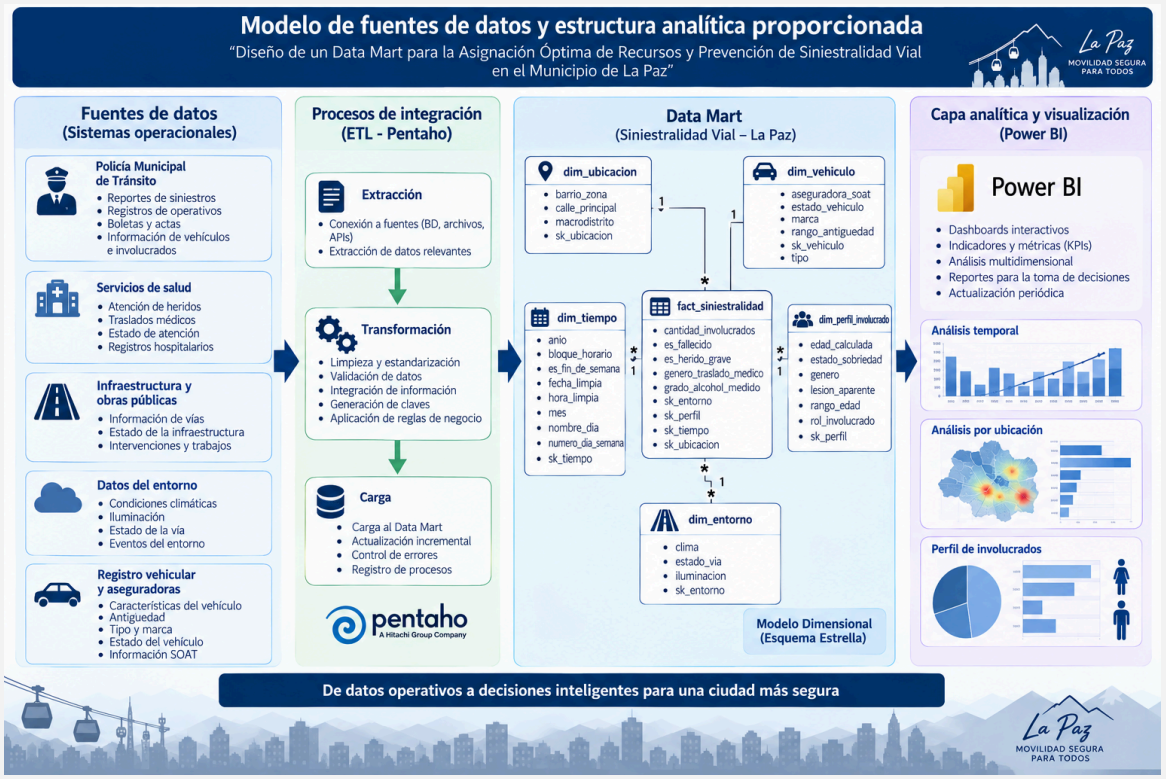

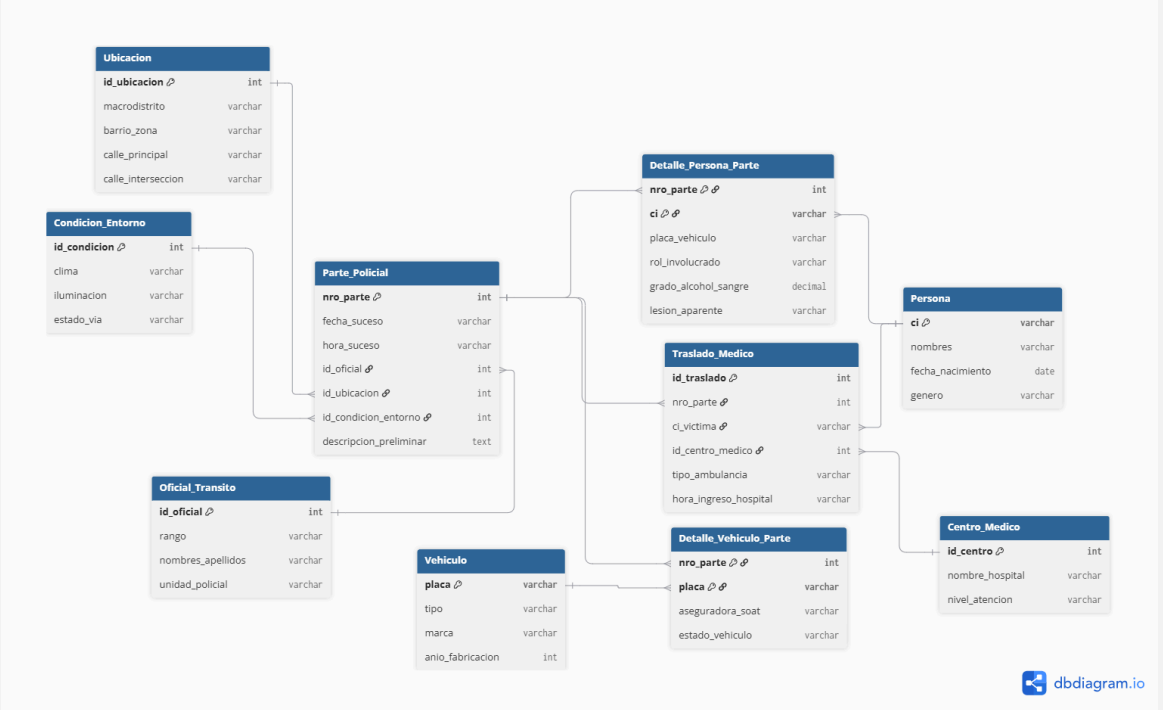

3.3 Requerimientos de información del negocio

Los requerimientos de información constituyen la base para definir los indicadores, perspectivas y visualizaciones del Data Mart. Para este proyecto se utilizarán los siete requerimientos proporcionados, organizados en tres niveles: estratégico, operacional y regulatorio.

Nivel Estratégico – Asignación de Presupuesto y Evaluación de Políticas

1. Priorización de Inversión en Infraestructura Vial

Nivel	Nivel Estratégico
Para quién es	Director de Infraestructura Vial (dependiente de la Secretaría Municipal de Infraestructura Pública).
Requerimiento (Pregunta)	¿Cuáles son los 5 macrodistritos y calles específicas donde la combinación de iluminación “Deficiente” y estado de vía “Malo” genera el mayor Índice de Severidad Histórico (ponderación de muertos y heridos)?
Justificativa	El presupuesto de la Alcaldía es limitado y el requerimiento busca proporcionar una base cuantitativa para priorizar puntos de intervención de infraestructura vial.
Cómo se hará y resultados en Power BI	Crear una medida DAX llamada Indice_Severidad con la expresión indicada en el requerimiento: ((Fallecidos × 10) + (Heridos × 5)) / Involucrados . Utilizar una Matriz o Mapa cruzando dim_ubicacion y dim_entorno y aplicar un filtro visual Top 5 basado en el índice.

2. Medición de Retorno de Inversión (ROI) en Obras

Nivel	Nivel Estratégico
Para quién es	Director de Proyectos y Programas (dependiente de la Secretaría Municipal de Planificación para el Desarrollo).
Requerimiento (Pregunta)	¿Cuál es la variación porcentual interanual (Año contra Año) de siniestros graves en las intersecciones donde se ejecutaron obras públicas el año pasado?
Justificativa	Permite evaluar si la evolución de los siniestros graves cambia después de una intervención pública.
Cómo se hará y resultados en Power BI	Usar funciones de Inteligencia de Tiempo en DAX, específicamente SAMEPERIODLASTYEAR, para crear la medida Variacion_YoY_%. Mostrar el comportamiento mediante un Gráfico de Líneas y Columnas agrupadas.

Nivel Operacional – Despliegue de Recursos y Patrullaje

3. Optimización de Operativos de Alcoholemia (Batidas)

Nivel	Nivel Operacional
Para quién es	Director de Control de la Circulación (dependiente de la Secretaría Municipal de Movilidad y Seguridad Ciudadana).

Requerimiento (Pregunta)	¿En qué días de la semana y bloques horarios específicos existe una concentración crítica de conductores con estado de sobriedad alterado que derivan en colisiones múltiples?
Justificativa	Busca focalizar los controles en los puntos, días y horarios donde los datos muestran mayor concentración de incidentes relacionados con sobriedad alterada.
Cómo se hará y resultados en Power BI	Construir un Mapa de Calor mediante una Matriz con formato condicional. Filas: dim_tiempo[nombre_dia]. Columnas: dim_tiempo[bloque_horario]. Valores: promedio de grado_alcohol_medido o conteo de incidentes.

4. Alerta Temprana de Saturación Hospitalaria

Nivel	Nivel Operacional
Para quién es	Director de Información y Estadística, coordinando con el Director de Seguridad Vial.
Requerimiento (Pregunta)	¿Qué condiciones climáticas específicas disparan exponencialmente los traslados médicos en vías de alta velocidad, superando el promedio estándar diario?
Justificativa	Permite identificar condiciones bajo las cuales los traslados médicos pueden superar el comportamiento promedio y apoyar la preparación preventiva de recursos.
Cómo se hará y resultados en Power BI	Crear una medida DAX que calcule el porcentaje de incremento de traslados sobre el promedio. Visualizarlo mediante un Gráfico de Dispersión (Scatter Plot), utilizando las condiciones climáticas y el comportamiento de los traslados.

5. Focalización de Campañas de Prevención

Nivel	Nivel Operacional
Para quién es	Director de Seguridad Vial.
Requerimiento (Pregunta)	¿Qué perfil demográfico (edad y género) concentra el mayor porcentaje de responsabilidad en accidentes con heridos graves, a fin de dirigir campañas educativas?
Justificativa	Busca orientar campañas de prevención hacia segmentos identificados mediante los datos, considerando rango de edad, género y macrodistrito.
Cómo se hará y resultados en Power BI	Utilizar un gráfico de Tornado o Pirámide Poblacional cruzando dim_perfil_involucrado[rango_edad] y [genero] con la métrica Total_Heridos_Graves.

Nivel Regulatorio – Políticas Públicas y Sanciones

6. Justificación para Restricción de Vehículos Antiguos

Nivel	Nivel Regulatorio
Para quién es	Director de Tránsito y Transporte municipal.

Requerimiento (Pregunta)	¿Qué porcentaje del total de fatalidades es provocado por el 20% del parque automotor más antiguo y que circula sin seguro SOAT vigente?
Justificativa	Busca cuantificar la participación de los vehículos más antiguos y sin SOAT vigente dentro de las fatalidades registradas, como insumo para análisis regulatorios.
Cómo se hará y resultados en Power BI	Crear un Gráfico de Pareto mediante líneas y columnas combinadas en DAX usando dim_vehiculo[rango_antiguedad]. Las columnas representan el total de muertos y la línea el porcentaje acumulado.

7. Auditoría y Sanción a Sindicatos de Transporte

Nivel	Nivel Regulatorio
Para quién es	Director de Tránsito y Transporte.
Requerimiento (Pregunta)	¿Qué Tipos de Vehículo (por ejemplo, Minibuses) registran una accidentabilidad por “Mal estado del vehículo” que supera la desviación estándar permitida para el transporte público?
Justificativa	Permite comparar el desempeño de los tipos de vehículo respecto de un promedio general y una referencia estadística.
Cómo se hará y resultados en Power BI	Crear una medida DAX avanzada que calcule el Promedio General de Accidentes y compare el desempeño individual de cada tipo de vehículo. Utilizar un Gráfico de Medidor (Gauge Chart) o un KPI visual.

Resultados:

📋 REQUERIMIENTO 1: Priorización de Inversión en Infraestructura Vial

- **Para quién es:** Director de Infraestructura Vial (Gobierno Autónomo Municipal de La Paz - GAMLP).
- **Pregunta de Negocio:** ¿En qué macrodistritos debemos priorizar el presupuesto de obras públicas (asfalto e iluminación) para reducir los accidentes más graves (fallecidos y heridos graves)?
- **Problema que resuelve:** El presupuesto de obras es limitado y a menudo se asigna por presión política. Este requerimiento elimina la subjetividad, permitiendo que la Alcaldía invierta donde las deficiencias de infraestructura (baches y falta de luz) causan el mayor daño a la vida humana.
- **KPIs Usados:**

    - **Índice de Severidad (Ponderado):** Mide la letalidad de los accidentes, no solo la cantidad.
- **Fórmulas DAX Clave:**

Fragmento de código

```
Indice_Severidad =
DIVIDE(
    (SUM(fact_siniestralidad[es_fallecido]) * 5) +
(SUM(fact_siniestralidad[es_herido_grave]) * 2),
    SUM(fact_siniestralidad[cantidad_involucrados]),
    0
)
```

- **Solución Visual (Qué mostrar en la defensa):** Matriz de Macrodistritos filtrada por condiciones críticas. Muestra claramente que Max Paredes (3,83) y Mallasa (3,39) deben recibir los contratos de asfaltado e iluminación urgente, porque sus índices de severidad superan la media de la ciudad (2,90).

Índice de Severidad en Condiciones Críticas de Infraestructura (Noche y Baches)

macrodistrito	Indice_Severidad
CENTRO	3,20
COTAHUMA	1,99
MALLASA	3,39
MAX PAREDES	3,83
PERIFERICA	2,50
SAN ANTONIO	2,87
ZONA SUR	2,76
Total	**2,90**

📋 REQUERIMIENTO 2: Auditoría y Retorno de Inversión (ROI) en Obras

- **Para quién es:** Director de Proyectos y Programas (Secretaría Municipal de Planificación para el Desarrollo).
- **Pregunta de Negocio:** ¿Cuál es la variación porcentual interanual (Año contra Año) de siniestros graves para evaluar si las obras públicas ejecutadas realmente redujeron la accidentalidad?
- **Problema que resuelve:** La Alcaldía gasta millones en pasarelas, señalización y semáforos, pero no tiene cómo auditar si funcionaron. Este modelo demuestra matemáticamente el "antes y después" de una intervención. Si los accidentes no bajan, se audita el proyecto o no se repite la política.

- **KPIs Usados:**
  - **Total de Siniestros Graves:** Sumatoria de heridos graves y fallecidos.
  - **Variación YoY % (Year over Year):** El porcentaje de crecimiento o reducción de accidentes frente al mismo mes del año pasado.
- **Fórmulas DAX Clave (Inteligencia de Tiempo):**

  Fragmento de código

  ```
  Total_Siniestros_Graves =
  SUM(fact_siniestralidad[es_herido_grave]) +
  SUM(fact_siniestralidad[es_fallecido])

  Graves_Anio_Anterior = CALCULATE([Total_Siniestros_Graves],
  SAMEPERIODLASTYEAR(Calendario[Date]))

  Variacion_YoY_% = DIVIDE([Total_Siniestros_Graves] -
  [Graves_Anio_Anterior], [Graves_Anio_Anterior], 0)
  ```

- **Solución Visual (Qué mostrar en la defensa):** Gráfico de líneas y columnas agrupadas por mes. La línea azul oscuro marca tendencias críticas (ej. pico de 126.88% en el mes 11), permitiendo al Director auditar por qué la política falló en esa fecha específica y aplicar correctivos.
- 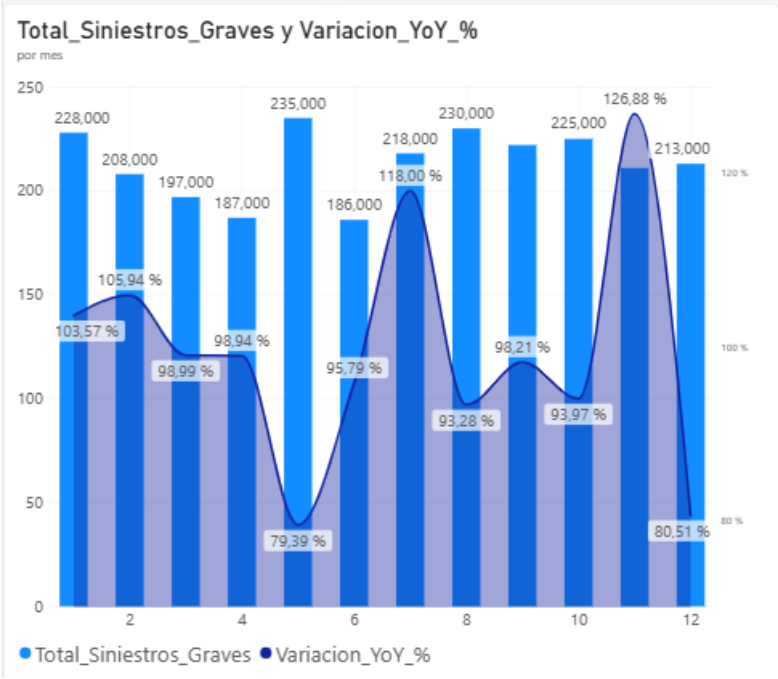

📋 REQUERIMIENTO COMPLEMENTARIO (Visión Gerencial)

- **KPI: Tasa de Mortalidad:** Muestra que el 19.66% de los involucrados en siniestros fallecen, una métrica directa de salud pública.

  Fragmento de código

  ```
  Tasa_Mortalidad_% =
  DIVIDE(SUM(fact_siniestralidad[es_fallecido]),
  SUM(fact_siniestralidad[cantidad_involucrados]), 0)
  ```

- **Gráfico de Impacto por Vehículo:** Define prioridades. Si un gran porcentaje de accidentes graves ocurre en Minibuses (15.47%) o Micros (14.14%), la Alcaldía prioriza la reparación de infraestructura en las vías troncales del transporte público masivo.

3.4 Definición de KPIs y métricas clave

A continuación se transforma cada requerimiento en indicadores, perspectivas y hechos o métricas de análisis. Se mantiene la lógica visual del informe de referencia, diferenciando por colores los conceptos de Indicador, Perspectiva, Hecho/Métrica y Nivel.

INDICADOR	PERSPECTIVA	HECHO / MÉTRICA	NIVEL

Indicador	Índice de Severidad Histórico
Perspectivas	Ubicación, Entorno
Hechos / Métricas	Fallecidos, Heridos graves, Involucrados
Función / cálculo	Según requerimiento: ((Fallecidos × 10) + (Heridos × 5)) / Involucrados
Aclaración	Se utiliza para identificar los cinco macrodistritos y calles con mayor severidad bajo iluminación deficiente y estado de vía malo.
Nivel	Nivel Estratégico

Indicador	Variación interanual de siniestros graves
Perspectivas	Tiempo, Ubicación
Hechos / Métricas	Siniestros graves
Función / cálculo	SAMEPERIODLASTYEAR / variación porcentual

Aclaración	Permite comparar el comportamiento de siniestros graves entre años en los contextos analizados.
Nivel	Nivel Estratégico

Indicador	Concentración de sobriedad alterada
Perspectivas	Tiempo, Perfil del involucrado
Hechos / Métricas	Grado de alcohol medido, conteo de incidentes
Función / cálculo	Promedio de grado_alcohol_medido o conteo de incidentes
Aclaración	Permite identificar días y bloques horarios con concentración crítica.
Nivel	Nivel Operacional

Indicador	Incremento de traslados médicos
Perspectivas	Entorno, Tiempo, Ubicación
Hechos / Métricas	Traslados médicos / promedio de traslados
Función / cálculo	% de incremento respecto al promedio
Aclaración	Permite analizar condiciones climáticas asociadas a incrementos de traslados médicos.
Nivel	Nivel Operacional

Indicador	Total de heridos graves por perfil
Perspectivas	Perfil del involucrado, Ubicación
Hechos / Métricas	Heridos graves, edad, género
Función / cálculo	Total_Heridos_Graves
Aclaración	Permite analizar el perfil demográfico asociado a accidentes con heridos graves.
Nivel	Nivel Operacional

Indicador	Porcentaje de fatalidades del parque automotor más antiguo
Perspectivas	Vehículo
Hechos / Métricas	Fallecidos, rango de antigüedad, aseguradora SOAT
Función / cálculo	Fatalidades del segmento / fatalidades totales; análisis Pareto
Aclaración	Permite estudiar la participación del parque automotor más antiguo y sin SOAT vigente.
Nivel	Nivel Regulatorio

Indicador	Accidentabilidad por estado del vehículo
Perspectivas	Vehículo
Hechos / Métricas	Accidentes, tipo de vehículo, estado del vehículo
Función / cálculo	Promedio general y comparación mediante desviación estándar
Aclaración	Permite identificar tipos de vehículo cuyo comportamiento se encuentra por encima de la referencia establecida.
Nivel	Nivel Regulatorio

Las perspectivas utilizadas en estos indicadores corresponden exclusivamente a las dimensiones presentes en el modelo proporcionado: Tiempo, Ubicación, Vehículo, Perfil del involucrado y Entorno. La tabla de hechos fact_siniestralidad contiene las claves y métricas necesarias para relacionar estas perspectivas.

3.5 Modelo conceptual del Data Mart

El modelo conceptual definitivo del proyecto se basa en una tabla de hechos central denominada fact_siniestralidad y cinco dimensiones: dim_tiempo, dim_ubicacion, dim_vehiculo, dim_perfil_involucrado y dim_entorno. Este modelo es el que se utilizará como referencia para las siguientes fases del proyecto y no se incorporarán dimensiones adicionales.

La tabla de hechos concentra los registros analíticos de siniestralidad y se relaciona con las dimensiones mediante sus claves sustitutas. Las dimensiones permiten analizar los hechos desde las perspectivas temporal, territorial, vehicular, del perfil de los involucrados y del entorno.

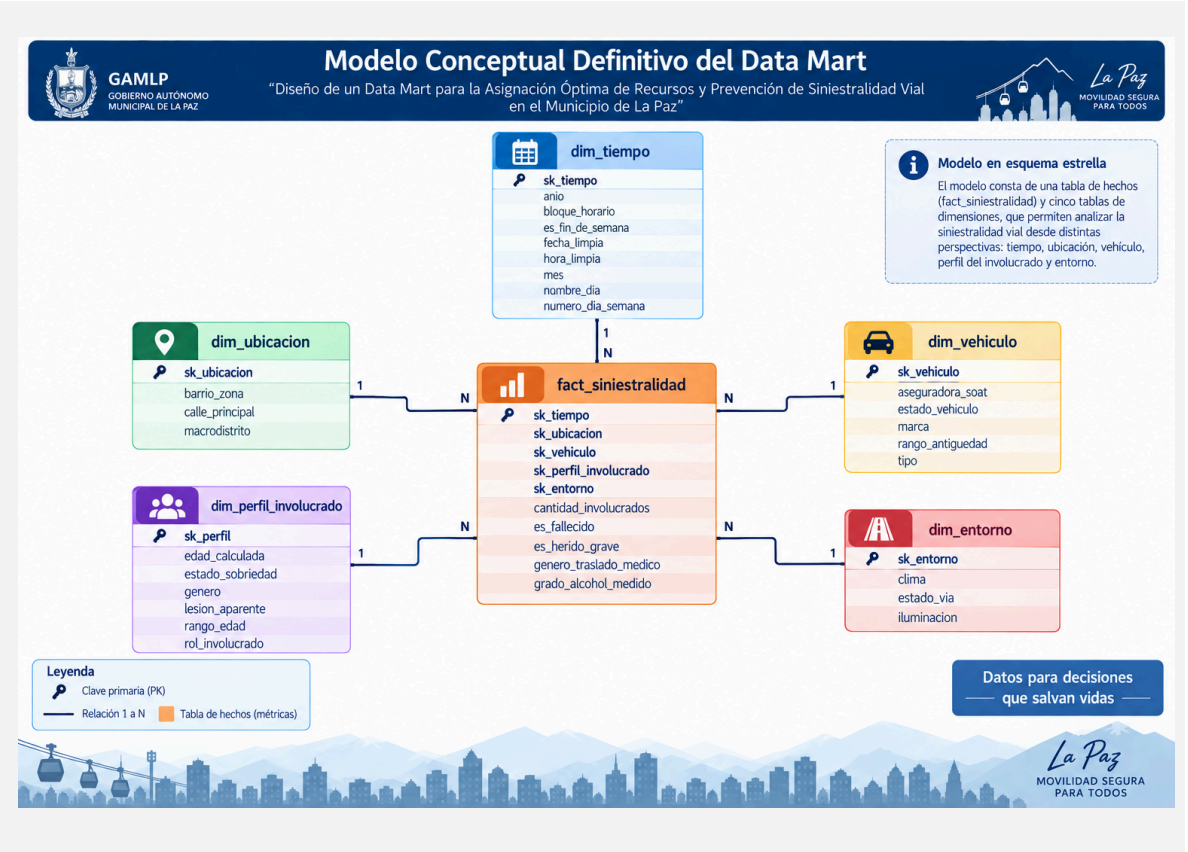

3.5.1 Entidades de negocio

fact_siniestralidad: Hecho central del Data Mart. Contiene métricas y atributos de análisis como cantidad_involucrados, es_fallecido, es_herido_grave, genero_traslado_medico, grado_alcohol_medido y las claves hacia las dimensiones.

dim_tiempo: Perspectiva temporal. Incluye año, bloque horario, indicador de fin de semana, fecha limpia, hora limpia, mes, nombre del día y número de día de la semana.

dim_ubicacion: Perspectiva geográfica. Incluye barrio/zona, calle principal, macrodistrito y clave de ubicación.

dim_vehiculo: Perspectiva vehicular. Incluye aseguradora SOAT, estado del vehículo, marca, rango de antigüedad, tipo y clave de vehículo.

dim_perfil_involucrado: Perspectiva de las personas involucradas. Incluye edad calculada, estado de sobriedad, género, lesión aparente, rango de edad, rol involucrado y clave de perfil.

dim_entorno: Perspectiva de condiciones del entorno. Incluye clima, estado de vía, iluminación y clave de entorno.

3.5.2 Relaciones de alto nivel

Las relaciones de alto nivel corresponden al modelo proporcionado y deberán mantenerse sin cambios en las fases posteriores.

- dim_ubicacion se relaciona con fact_siniestralidad mediante sk_ubicacion.
- dim_tiempo se relaciona con fact_siniestralidad mediante sk_tiempo.
- dim_vehiculo se relaciona con fact_siniestralidad mediante sk_vehiculo.
- dim_perfil_involucrado se relaciona con fact_siniestralidad mediante sk_perfil.
- dim_entorno se relaciona con fact_siniestralidad mediante sk_entorno.
- fact_siniestralidad constituye el lado de los hechos y las dimensiones proporcionan las perspectivas para su filtrado y agrupación.

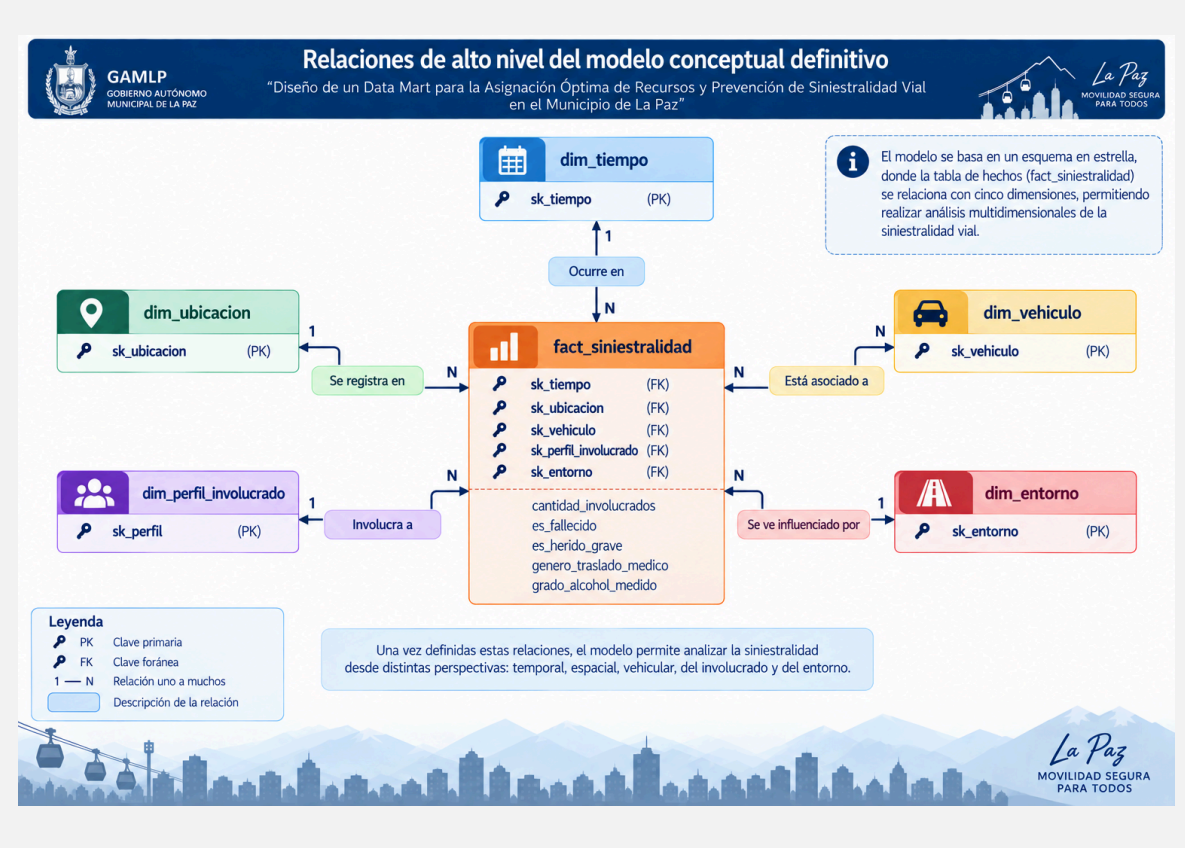

3.5.3 Hechos e Indicadores

En este punto se explicita cómo los hechos y atributos del modelo permiten calcular los indicadores definidos en los requerimientos. La representación sigue la lógica del informe de referencia mediante bloques diferenciados.

Indicador	Índice de Severidad Histórico
Perspectivas	dim_ubicacion, dim_entorno
Hechos / Métricas	fact_siniestralidad.es_fallecido, fact_siniestralidad.es_herido_grave, fact_siniestralidad.cantidad_involucrados
Función / cálculo	Según el requerimiento: ((Fallecidos × 10) + (Heridos × 5)) / Involucrados
Aclaración	Se filtra iluminación = “Deficiente” y estado_via = “Malo” y se seleccionan los cinco resultados superiores.
Nivel	Nivel Estratégico

Indicador	Variacion_YoY_%
Perspectivas	dim_tiempo, dim_ubicacion
Hechos / Métricas	Siniestros graves
Función / cálculo	SAMEPERIODLASTYEAR y variación porcentual
Aclaración	Compara años y permite observar la evolución posterior a intervenciones cuando esa información se encuentre disponible.
Nivel	Nivel Estratégico

Indicador	Concentración de sobriedad alterada
Perspectivas	dim_tiempo, dim_perfil_involucrado
Hechos / Métricas	fact_siniestralidad.grado_alcohol_medido; dim_perfil_involucrado.estado_sobriedad
Función / cálculo	Promedio o conteo de incidentes
Aclaración	Permite construir la matriz de día de semana por bloque horario.
Nivel	Nivel Operacional

Indicador	Incremento de traslados médicos
Perspectivas	dim_entorno, dim_tiempo, dim_ubicacion
Hechos / Métricas	Traslados médicos
Función / cálculo	% de incremento sobre el promedio
Aclaración	Se analiza conjuntamente con clima y condiciones de vía/ubicación según los atributos disponibles.
Nivel	Nivel Operacional

Indicador	Total_Heridos_Graves
Perspectivas	dim_perfil_involucrado, dim_ubicacion
Hechos / Métricas	fact_siniestralidad.es_herido_grave; edad, género y rango de edad
Función / cálculo	Conteo / suma de la condición de herido grave
Aclaración	Permite representar el perfil demográfico mediante Tornado o Pirámide Poblacional.
Nivel	Nivel Operacional

Indicador	Porcentaje de fatalidades por antigüedad y SOAT
Perspectivas	dim_vehiculo
Hechos / Métricas	fact_siniestralidad.es_fallecido; dim_vehiculo.rango_antiguedad; dim_vehiculo.aseguradora_soat
Función / cálculo	Porcentaje acumulado / Pareto
Aclaración	Permite analizar la participación del segmento más antiguo y sin SOAT vigente según el requerimiento.
Nivel	Nivel Regulatorio

Indicador	Accidentabilidad por mal estado del vehículo
Perspectivas	dim_vehiculo
Hechos / Métricas	Accidentes; dim_vehiculo.tipo; dim_vehiculo.estado_vehiculo
Función / cálculo	Promedio general, desviación estándar y comparación por tipo
Aclaración	Permite identificar tipos de vehículo que superen la referencia definida.
Nivel	Nivel Regulatorio

Con este modelo conceptual y la definición de indicadores se completa la Fase de Análisis. En la Fase de Diseño se desarrollará el modelo conceptual aumentado, la granularidad, las jerarquías, las tablas dimensionales y de hechos, las claves, cardinalidades, el esquema estrella y los procesos ETL, manteniendo como referencia obligatoria el modelo presentado.

4 FASE DE DISEÑO

En esta fase se transforma el análisis realizado en la etapa anterior en una propuesta dimensional formal para el Data Mart. El diseño se construye respetando el modelo conceptual definitivo proporcionado para el proyecto y manteniendo sus perspectivas de análisis: Tiempo, Ubicación, Vehículo, Perfil del Involucrado y Entorno. La tabla central corresponde a fact_siniestralidad.

La estructura sigue la lógica utilizada en el informe de referencia: primero se amplía el modelo conceptual, luego se establece la granularidad y las jerarquías, se define el modelo lógico, se detallan dimensiones y hechos, se presenta el esquema estrella y finalmente se documenta el proceso ETL.

4.1 Modelo conceptual aumentado

El modelo conceptual aumentado incorpora al modelo conceptual definitivo los elementos necesarios para explicar con precisión qué se analizará, desde qué perspectivas y con qué indicadores. En esta etapa se conserva la estructura establecida previamente y se hace explícita la correspondencia entre el hecho central y sus dimensiones.

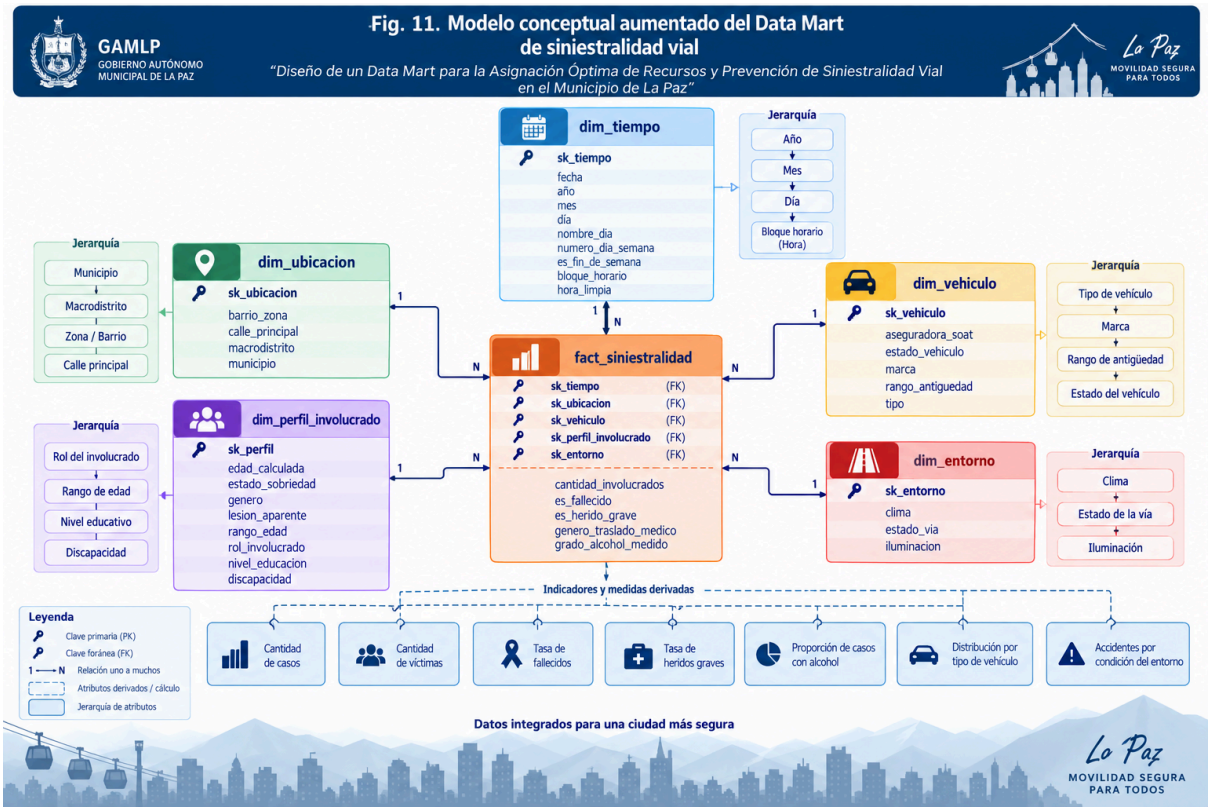

Figura 11. Modelo conceptual aumentado del Data Mart de siniestralidad vial.

4.1.1 Definición de hechos y dimensiones

El modelo está organizado alrededor del hecho fact_siniestralidad, que representa el registro analítico de un evento de siniestralidad y permite asociarlo con las diferentes perspectivas de análisis. Las dimensiones permiten segmentar la información según tiempo, ubicación, vehículo, perfil del involucrado y condiciones del entorno.

Elemento	Tipo	Función analítica
fact_siniestralidad	**Tabla de hechos**	**Concentra las claves dimensionales y los indicadores/atributos medibles del evento.**
dim_tiempo	**Dimensión**	**Permite analizar los siniestros por año, mes, día, día de semana y otros atributos temporales.**
dim_ubicacion	**Dimensión**	**Permite analizar la distribución espacial mediante barrio/zona, calle principal y macrodistrito.**
dim_vehiculo	**Dimensión**	**Permite analizar los vehículos involucrados según tipo, marca, antigüedad y estado.**
dim_perfil_involucrado	**Dimensión**	**Permite analizar características del involucrado como género, edad, rango de edad, rol y estado de sobriedad.**
dim_entorno	**Dimensión**	**Permite analizar las condiciones del entorno como clima, estado de la vía e iluminación.**

Esta definición mantiene las cinco dimensiones observadas en el modelo proporcionado y evita incorporar dimensiones adicionales que no forman parte del diseño definitivo.

4.1.2 Granularidad y jerarquías

La granularidad define el nivel de detalle de cada registro de la tabla de hechos. Para este Data Mart, el diseño se establece a nivel de evento de siniestralidad registrado, asociado a un momento temporal, una ubicación, un vehículo, un perfil de involucrado y unas condiciones de entorno. Esta definición permite realizar agregaciones sin perder las principales perspectivas de análisis.

Dimensión	Jerarquía / niveles de análisis	Ejemplos de atributos
Tiempo	**Año → Mes → Día**	**año, mes, fecha_limpia, nombre_dia, numero_dia_semana, es_fin_de_semana**
Ubicación	**Macrodistrito → Zona/Barrio → Calle principal**	**macrodistrito, barrio_zona, calle_principal**
Vehículo	**Tipo → Marca → Rango de antigüedad**	**tipo, marca, rango_antiguedad, estado_vehiculo**
Perfil involucrado	**Rango de edad → Género / Rol**	**rango_edad, edad_calculada, genero, rol_involucrado, estado_sobriedad**
Entorno	**Condición ambiental y vial**	**clima, estado_via, iluminacion**

Las jerarquías se utilizarán para facilitar el análisis de los indicadores desde diferentes niveles de agregación, por ejemplo, desde el comportamiento anual hasta el análisis por mes o desde un macrodistrito hasta una zona y calle principal.

4.1.3 Esquema dimensional preliminar

El esquema dimensional preliminar muestra la relación conceptual entre la tabla de hechos y las cinco dimensiones. Su propósito es servir como transición hacia el modelo lógico y el esquema estrella definitivo.

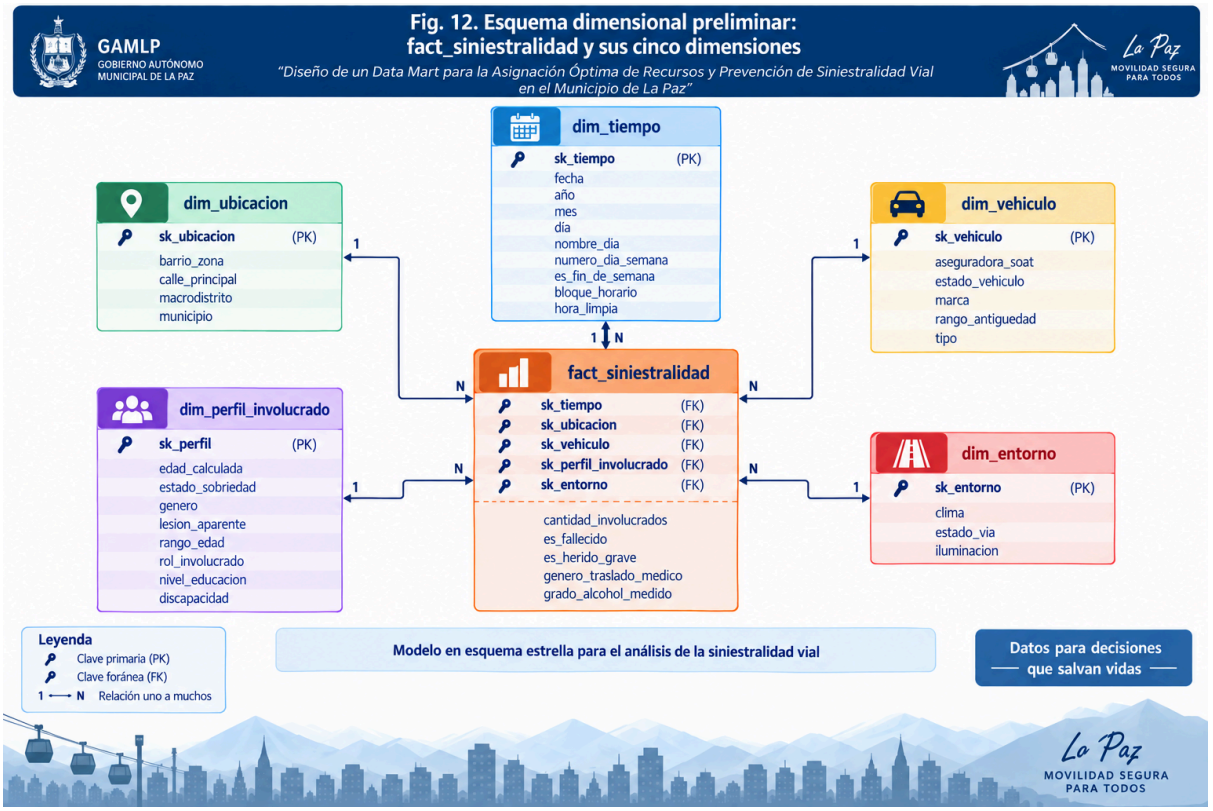

Figura 12. Esquema dimensional preliminar.

4.2 Modelo lógico del Data Warehouse

El modelo lógico traduce el diseño conceptual a estructuras relacionales que podrán implementarse en el Data Mart. Se mantienen las tablas de dimensiones y la tabla de hechos definidas anteriormente, utilizando claves sustitutas (SK) como identificadores de las dimensiones.

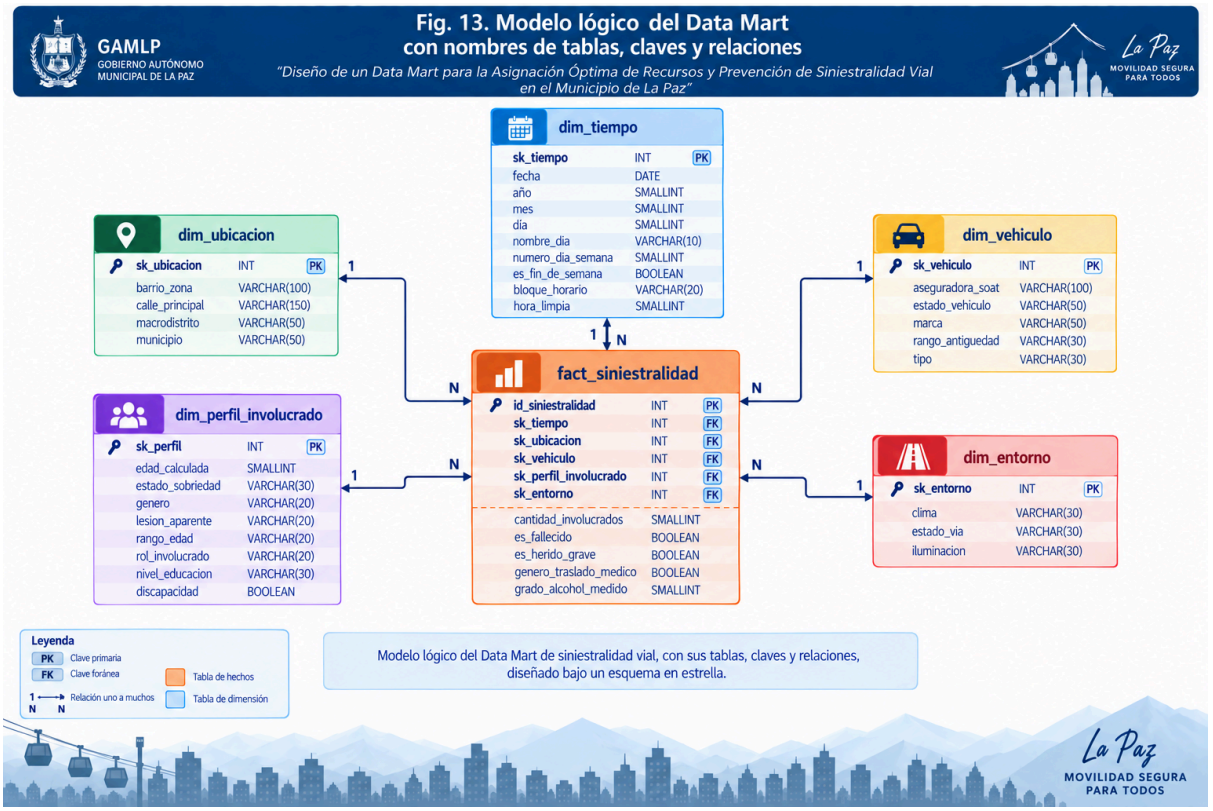

Figura 13. Modelo lógico del Data Mart.

4.2.1 Tablas de dimensiones

Cada dimensión contiene atributos descriptivos utilizados para segmentar, filtrar y contextualizar los indicadores almacenados en fact_siniestralidad.

Dimensión	Clave sustituta	Atributos principales
dim_tiempo	**sk_tiempo**	**año, mes, nombre_dia, numero_dia_semana, fecha_limpia, hora_limpia, bloque_horario, es_fin_de_semana**
dim_ubicacion	**sk_ubicacion**	**barrio_zona, calle_principal, macrodistrito**
dim_vehiculo	**sk_vehiculo**	**aseguradora_soat, estado_vehiculo, marca, rango_antiguedad, tipo**
dim_perfil_involucrado	**sk_perfil**	**edad_calculada, estado_sobriedad, genero, rango_edad, rol_involucrado**
dim_entorno	**sk_entorno**	**clima, estado_via, iluminacion**

Los nombres de atributos anteriores corresponden a la estructura visual del modelo proporcionado. La definición detallada de tipos de datos y restricciones se documentará en la etapa de implementación.

4.2.2 Tablas de hechos

La tabla fact_siniestralidad constituye el núcleo del modelo. Contiene las claves foráneas que conectan el evento con las dimensiones y los campos necesarios para el análisis cuantitativo y descriptivo.

Tabla	Grano	Campos/medidas relevantes
fact_siniestralidad	Un registro analítico por evento de siniestralidad e involucramiento asociado	sk_tiempo, sk_ubicacion, sk_vehiculo, sk_perfil, sk_entorno, cantidad_involucrados, es_fallecido, es_herido_grave, genero_traslado_medico, grado_alcohol_medido

La interpretación de cada campo deberá respetar la definición establecida en la base implementada. En particular, los indicadores derivados deberán evitar duplicaciones al realizar agregaciones sobre los datos.

4.2.3 Claves primarias y foráneas

Las dimensiones utilizan claves sustitutas (SK) como identificadores internos. La tabla de hechos almacena las claves correspondientes para establecer las relaciones de tipo muchos-a-uno desde el hecho hacia cada dimensión.

Tabla	Clave primaria	Claves foráneas
dim_tiempo	sk_tiempo	—
dim_ubicacion	sk_ubicacion	—
dim_vehiculo	sk_vehiculo	—
dim_perfil_involucrado	sk_perfil	—
dim_entorno	sk_entorno	—
fact_siniestralidad	Clave propia del registro de hecho, según implementación	sk_tiempo, sk_ubicacion, sk_vehiculo, sk_perfil, sk_entorno

Las relaciones se establecen de forma que una fila de dimensión pueda estar asociada a múltiples registros de la tabla de hechos, mientras cada registro de hechos referencia una combinación concreta de dimensiones.

4.2.4 Atributos y cardinalidades

La cardinalidad esperada del modelo dimensional es de 1:N desde cada dimensión hacia fact_siniestralidad. Esto permite que una misma fecha, ubicación, categoría de vehículo, perfil o condición de entorno aparezca en múltiples registros de siniestralidad.

Relación	Cardinalidad	Interpretación
dim_tiempo → fact_siniestralidad	1 : N	Un registro temporal puede estar asociado a muchos siniestros.
dim_ubicacion → fact_siniestralidad	1 : N	Una ubicación puede concentrar múltiples eventos.
dim_vehiculo → fact_siniestralidad	1 : N	Una categoría/registro de vehículo puede aparecer en múltiples eventos.
dim_perfil_involucrado → fact_siniestralidad	1 : N	Un perfil dimensional puede asociarse a múltiples registros.
dim_entorno → fact_siniestralidad	1 : N	Una condición de entorno puede aparecer en múltiples eventos.

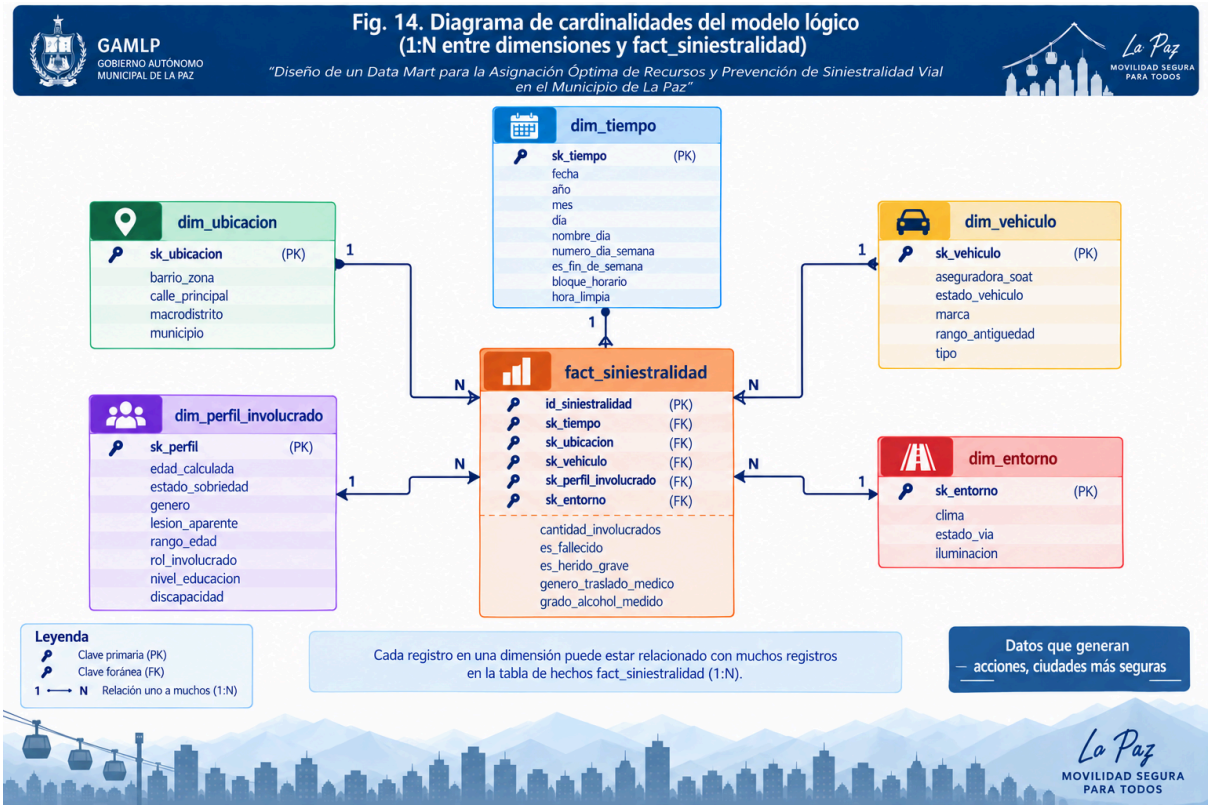

Figura 14. Cardinalidades del modelo lógico.

4.3 Diseño de la arquitectura del Data Warehouse (Star Schema)

El Data Mart adopta un esquema estrella debido a que una tabla de hechos central se relaciona directamente con dimensiones descriptivas. Esta organización facilita las consultas analíticas y la construcción de visualizaciones en Power BI.

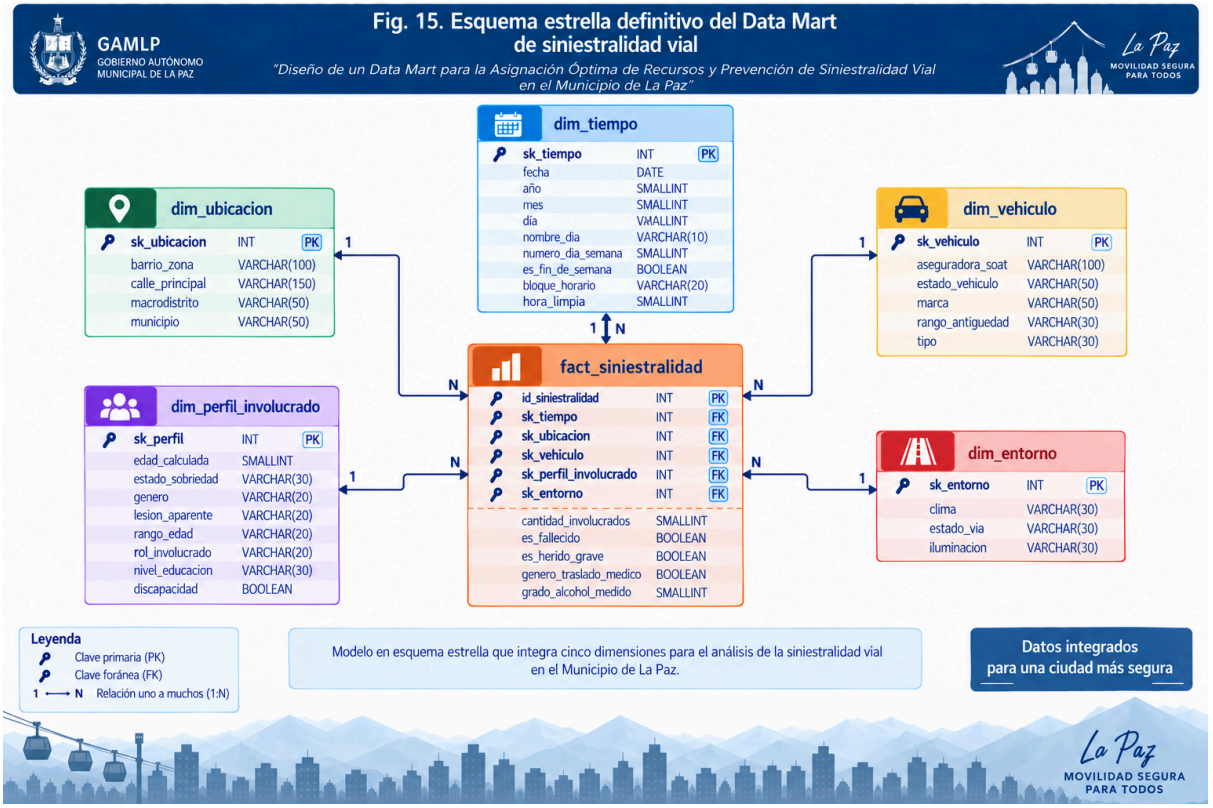

Figura 15. Esquema estrella definitivo.

En el centro se ubica fact_siniestralidad y alrededor se encuentran dim_tiempo, dim_ubicacion, dim_vehiculo, dim_perfil_involucrado y dim_entorno. La disposición debe conservar exactamente estas cinco dimensiones y sus claves de relación.

4.4 Definición de procesos ETL

El proceso ETL constituye el mecanismo mediante el cual los datos de la fuente son extraídos, transformados y cargados al Data Mart. Para este proyecto se utilizará Pentaho Data Integration (PDI), manteniendo separadas las actividades de extracción, limpieza, transformación y carga.

Etapa	Actividades previstas	Resultado
Extracción	**Lectura de los datos desde la fuente y selección de los campos requeridos.**	**Datos disponibles para procesamiento.**
Transformación	**Limpieza, normalización, conversión de tipos, tratamiento de valores nulos y generación de atributos analíticos.**	**Datos consistentes y preparados para el modelo dimensional.**
Construcción de dimensiones	**Carga de dim_tiempo, dim_ubicacion, dim_vehiculo, dim_perfil_involucrado y dim_entorno.**	**Dimensiones pobladas.**
Carga de hechos	**Integración de claves sustitutas y carga de fact_siniestralidad.**	**Tabla de hechos poblada.**
Validación	**Comparación de registros, revisión de nulos, duplicados y consistencia de relaciones.**	**Data Mart validado.**

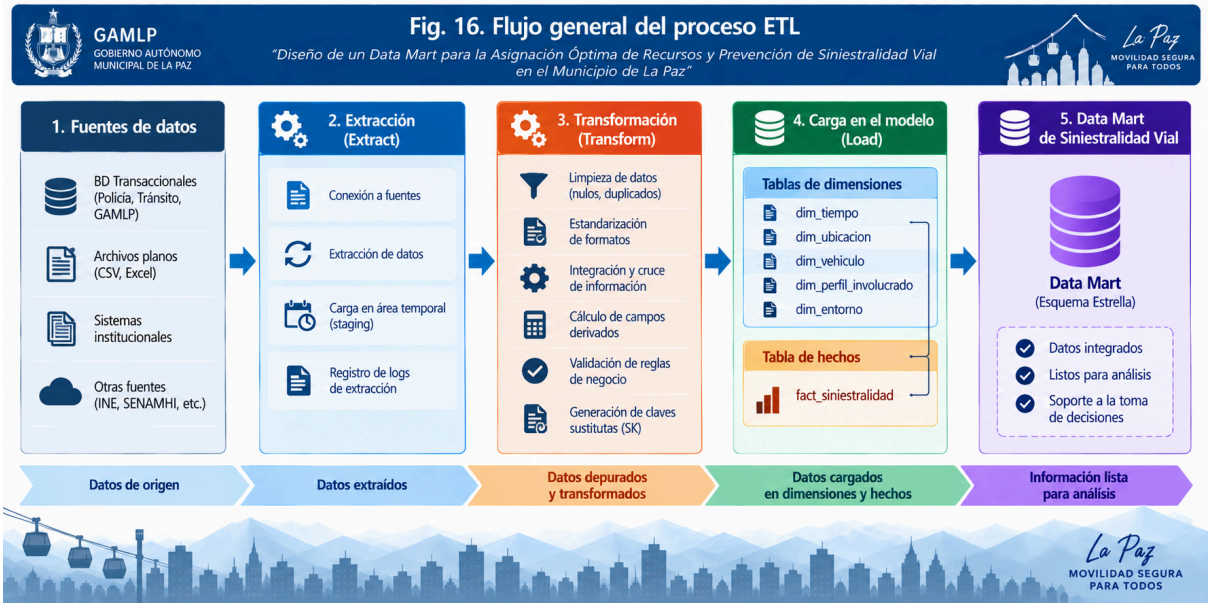

Figura 16. Flujo general del proceso ETL.

Resumen de la fase de diseño

La fase de diseño establece la estructura dimensional que será implementada posteriormente. El modelo queda conformado por una tabla de hechos central, fact_siniestralidad, y cinco dimensiones: tiempo, ubicación, vehículo, perfil del involucrado y entorno. La definición de granularidad, jerarquías, claves, cardinalidades y proceso ETL permite pasar de la definición conceptual a una estructura preparada para su implementación en PostgreSQL, Pentaho Data Integration y Power BI.

5 FASE DE CONSTRUCCIÓN

5.1 Implementación del Data Warehouse con Pentaho

La fase de construcción comprende la implementación del modelo dimensional definido en la etapa de diseño y la construcción de los procesos de extracción, transformación y carga (ETL). Para este proyecto se utilizó Pentaho Data Integration (PDI) como herramienta principal para integrar la información proveniente del Sistema Integrado de Siniestralidad y Movilidad y preparar los datos para su análisis multidimensional.

El proceso de construcción se orientó a generar un Data Mart especializado en siniestralidad vial, compuesto por una tabla de hechos denominada fact_siniestralidad y las dimensiones dim_tiempo, dim_ubicacion, dim_vehiculo, dim_perfil_involucrado y dim_entorno.

La utilización de dimensiones independientes permite organizar la información desde diferentes perspectivas de análisis, facilitando posteriormente la construcción de indicadores y visualizaciones en Power BI.

5.1.1 Instalación y configuración de Pentaho Data Integration (PDI)

Para la implementación de los procesos ETL se utilizó Pentaho Data Integration (PDI), herramienta que permite diseñar transformaciones mediante componentes gráficos y conectarlas con diferentes fuentes y destinos de datos.

La configuración del entorno permitió establecer la conexión con la base de datos fuente y con la base de datos destinada al Data Mart. A partir de estas conexiones se desarrollaron transformaciones independientes para la carga de las dimensiones y una transformación específica para la construcción de la tabla de hechos.

La organización de los procesos permitió separar las operaciones de carga de dimensiones de la carga de la tabla de hechos, facilitando la ejecución, revisión y mantenimiento de cada transformación.

Las principales transformaciones consideradas fueron:

- dim_tiempo
- dim_ubicacion
- dim_vehiculo
- dim_perfilInvolucrado
- dim_entorno
- fact_siniestralidad

Esta estructura permite que las dimensiones sean preparadas antes de realizar la carga de los registros correspondientes a la tabla de hechos.

5.1.2 Extracción de datos desde las fuentes

La extracción de información se realizó a partir de la base de datos operacional del Sistema Integrado de Siniestralidad y Movilidad.

La fuente contiene información relacionada con partes policiales, ubicaciones, condiciones del entorno, vehículos, personas involucradas, oficiales de tránsito, traslados médicos y centros médicos.

Entre las principales tablas utilizadas como fuente se encuentran:

- Ubicacion
- Condicion_Entorno
- Oficial_Transito
- Parte_Policial
- Vehiculo
- Persona
- Detalle_Vehiculo_Parte

- Detalle_Persona_Parte
- Centro_Medico
- Traslado_Medico

La extracción permitió obtener los atributos necesarios para construir las dimensiones y posteriormente formar los registros de la tabla de hechos.

Una característica importante de la fuente es que algunos campos fueron almacenados en formatos que requieren tratamiento antes de su utilización analítica. Por ejemplo, las fechas y horas del suceso requieren procesos de limpieza y normalización antes de relacionarse con la dimensión temporal.

Asimismo, existen datos categóricos que pueden presentar diferencias de escritura o formato, por lo que fueron considerados dentro del proceso de transformación.

5.1.3 Transformación y limpieza de datos

La transformación constituye una de las etapas principales del proceso ETL, debido a que los datos extraídos de la fuente operacional deben ser preparados para cumplir con las características requeridas por el modelo dimensional.

Durante esta etapa se realizaron procesos de limpieza, normalización, conversión y generación de nuevos atributos.

Tratamiento de fechas y horasLos campos relacionados con la fecha y hora del suceso fueron preparados para poder asociarlos con las dimensiones temporales. Esto permite obtener atributos como año, mes, día, día de la semana, condición de fin de semana, bloque horario y hora de ocurrencia.

Normalización de información geográficaLos datos de ubicación fueron preparados para mantener una representación consistente de los macrodistritos, barrios, calles y demás atributos utilizados para el análisis territorial.

Tratamiento de información vehicularLos datos relacionados con los vehículos fueron normalizados para permitir el análisis por tipo de vehículo, marca, estado del vehículo, antigüedad y aseguradora SOAT.

Tratamiento del perfil de los involucradosLa información de las personas involucradas fue transformada para generar variables analíticas como género, edad, rango de edad, rol involucrado, estado de lesión y grado de alcohol registrado. La edad puede ser calculada a partir de la fecha de nacimiento y la fecha del suceso, permitiendo posteriormente agrupar a los involucrados por rangos etarios.

Tratamiento de las condiciones del entornoLa información relacionada con el entorno fue normalizada considerando variables como clima, iluminación y estado de la vía. Estas variables permiten estudiar la relación entre las condiciones ambientales y las características de los siniestros registrados.

Generación de variables derivadasDurante la transformación también se generan variables necesarias para el análisis, entre ellas indicadores relacionados con cantidad de involucrados, presencia de fallecidos, presencia de heridos graves, edad calculada, información relacionada con alcohol y características del entorno.

El resultado de esta etapa es un conjunto de datos limpio y estructurado, preparado para ser asociado con las claves sustitutas de las dimensiones.

5.1.4 Carga en el Data Warehouse (ETL completo)

Una vez realizadas las transformaciones, se procedió a cargar la información en las tablas correspondientes del Data Mart.

La carga se organizó en dos grandes grupos:

Dimensiones:

- dim_tiempo
- dim_ubicacion
- dim_vehiculo
- dim_perfil_involucrado
- dim_entorno

Tabla de hechos:

- fact_siniestralidad

La carga de las dimensiones permite disponer previamente de las claves sustitutas que posteriormente serán utilizadas por la tabla de hechos.

Para la construcción de fact_siniestralidad, los datos transformados son relacionados con las dimensiones correspondientes mediante procesos de búsqueda de claves. De esta manera, cada registro de la tabla de hechos puede quedar asociado con una ubicación, un momento temporal, un vehículo, un perfil de involucrado y una condición del entorno.

La tabla de hechos concentra las variables cuantificables y los atributos necesarios para responder a los requerimientos de información establecidos durante la fase de análisis.

El flujo general del proceso puede resumirse como: Fuente operacional → Extracción → Transformación → Búsqueda de dimensiones → Carga de dimensiones y hechos → Data Mart.

5.2 Creación de Dashboards con Power BI

Una vez finalizada la construcción del Data Mart, se utilizó Microsoft Power BI como herramienta de análisis y visualización.

El objetivo de esta etapa fue convertir los datos almacenados en el modelo dimensional en información comprensible mediante indicadores, gráficos, tablas y filtros interactivos.

El dashboard permite analizar la siniestralidad desde diferentes perspectivas y facilita la exploración de la información según variables temporales, geográficas, vehiculares, de perfil de los involucrados y del entorno.

5.2.1 Conexión de Power BI con el Data Warehouse

Power BI fue conectado con las estructuras correspondientes al Data Mart.

La conexión permitió incorporar las dimensiones y la tabla de hechos para construir el modelo analítico utilizado en los reportes.

Las principales estructuras consideradas fueron:

- dim_tiempo
- dim_ubicacion
- dim_vehiculo
- dim_perfil_involucrado
- dim_entorno
- fact_siniestralidad

A partir de esta estructura, Power BI puede utilizar las relaciones entre las dimensiones y la tabla de hechos para realizar agregaciones y filtros dinámicos.

5.2.2 Modelado de datos en Power BI

El modelo implementado en Power BI mantiene la lógica dimensional desarrollada en el Data Mart.

La tabla fact_siniestralidad constituye el centro del análisis y se relaciona con las dimensiones mediante sus respectivas claves.

Este modelo permite realizar análisis multidimensionales sin necesidad de consultar directamente las tablas operacionales de origen.

Las principales perspectivas disponibles son:

- Tiempo: análisis por año, mes, día y bloque horario.
- Ubicación: análisis por macrodistrito, barrio y ubicación.
- Vehículo: análisis por tipo, marca, estado y antigüedad.
- Perfil del involucrado: análisis por género, edad, rango de edad y rol.
- Entorno: análisis por clima, iluminación y estado de la vía.

Esta estructura permite combinar diferentes dimensiones para identificar patrones de comportamiento de la siniestralidad.

5.2.3 Creación de visualizaciones y reportes

A partir del modelo dimensional se construyeron visualizaciones orientadas a los requerimientos de información definidos en la fase de análisis.

Entre las principales visualizaciones se consideran:

- indicadores generales de siniestralidad;
- indicadores de gravedad;
- indicadores relacionados con mortalidad;
- análisis temporal;
- análisis por ubicación;
- análisis por tipo de vehículo;
- análisis por perfil de los involucrados;
- análisis de condiciones ambientales;

- comparaciones entre períodos.

Los filtros interactivos permiten segmentar la información según variables como clima, macrodistrito, período, tipo de vehículo y características del involucrado.

De esta manera, el dashboard funciona como una herramienta de exploración y análisis para apoyar la identificación de zonas, períodos y condiciones que requieren especial atención.

5.2.4 Publicación y despliegue de dashboards

Una vez construidos los reportes, estos pueden ser publicados mediante el entorno de Power BI correspondiente para permitir su consulta por los usuarios autorizados.

El despliegue debe considerar aspectos como disponibilidad de la fuente de datos, actualización de la información, permisos de acceso, mantenimiento del modelo, actualización de las medidas y disponibilidad de los dashboards.

En el contexto académico del proyecto, el dashboard constituye el producto final de la cadena de Business Intelligence, ya que presenta la información transformada en indicadores y visualizaciones comprensibles para el análisis de la siniestralidad vial.

6 FASE DE IMPLANTACIÓN

6.1 Validación de datos y consistencia

La validación permitió comprobar que la información cargada en el Data Mart mantiene correspondencia con los datos provenientes de la fuente operacional.

Se verificaron principalmente:

- existencia de registros en las dimensiones;
- correspondencia de claves;
- relaciones entre dimensiones y hechos;
- presencia de valores nulos;
- consistencia de categorías;
- correcta asociación temporal;
- correcta asociación geográfica;
- correspondencia de vehículos e involucrados.

También se verificó que los procesos ETL puedan completar la carga de las estructuras correspondientes sin generar registros huérfanos en las relaciones dimensionales.

La validación es importante porque un error durante la transformación podría propagarse posteriormente a los indicadores y visualizaciones.

6.2 Pruebas de rendimiento

Las pruebas de rendimiento estuvieron orientadas a verificar el comportamiento del proceso de carga y del modelo analítico.

Se consideraron aspectos como:

- tiempo requerido para ejecutar las transformaciones;
- cantidad de registros procesados;
- tiempo de carga de las dimensiones;
- tiempo de carga de la tabla de hechos;
- respuesta de las consultas analíticas;
- comportamiento de los filtros en Power BI.

El modelo dimensional permite reducir la complejidad de las consultas analíticas al organizar la información en dimensiones y una tabla de hechos central.

Para una implementación productiva, estas pruebas podrían ampliarse considerando volúmenes mayores de información y ejecuciones periódicas automatizadas.

6.3 Verificación de KPIs y métricas

La verificación de los indicadores permitió comprobar que las medidas utilizadas en Power BI correspondan con los requerimientos definidos durante la fase de análisis.

Entre los principales indicadores considerados se encuentran:

- cantidad de siniestros;
- cantidad de involucrados;
- cantidad de siniestros graves;
- índice de severidad;
- tasa de mortalidad;
- distribución temporal;
- distribución por ubicación;
- distribución por tipo de vehículo;
- comportamiento según características del perfil;
- comportamiento según condiciones del entorno.

La comprobación de estos indicadores permite garantizar que las visualizaciones presentadas en el dashboard representen correctamente la información almacenada en el Data Mart.

6.4 Implementación en el entorno de producción

La implementación del proyecto contempla la utilización conjunta de las herramientas que forman parte de la arquitectura de Business Intelligence.

El flujo implementado es: Base de datos operacional → Pentaho Data Integration → Data Mart → Power BI → Dashboard.

En un entorno de producción, el proceso ETL puede ser programado para ejecutarse periódicamente, permitiendo incorporar nuevos registros y actualizar las dimensiones y hechos.

La implementación productiva requiere además establecer mecanismos de control de acceso, respaldo de información, monitoreo de los procesos ETL y mantenimiento del modelo.

En el alcance académico del proyecto, se considera como resultado principal la implementación funcional del proceso de integración y del modelo analítico.

6.5 Documentación del proceso ETL y del modelo de datos

La documentación del proyecto permite describir la relación entre la fuente operacional, los procesos ETL y el Data Mart.

Se documentaron:

- fuentes de información;
- dimensiones;
- tabla de hechos;
- campos utilizados;
- transformaciones realizadas;
- reglas de limpieza;
- relaciones entre tablas;
- indicadores;
- modelo de Power BI.

Esta documentación facilita el mantenimiento del proyecto y permite comprender el recorrido de la información desde su origen hasta la visualización final.

6.6 Manual de usuario para Power BI

El dashboard fue diseñado para permitir la consulta de información mediante indicadores, gráficos y filtros.

El usuario puede comenzar revisando los indicadores generales y posteriormente aplicar filtros para profundizar el análisis.

El flujo básico de utilización es:

1. Ingresar al dashboard.
2. Revisar los indicadores generales.
3. Seleccionar el período de análisis.
4. Seleccionar el macrodistrito u otra ubicación.
5. Aplicar filtros relacionados con clima o características del vehículo.
6. Analizar los gráficos resultantes.
7. Comparar los resultados obtenidos.
8. Utilizar la información como apoyo para identificar necesidades de prevención y atención.

La interacción con los filtros permite modificar dinámicamente los resultados mostrados en las visualizaciones.

7 FASE DE EVALUACIÓN

7.1 Resultados obtenidos

La implementación del Data Mart permitió integrar información relacionada con la siniestralidad vial en un modelo orientado específicamente al análisis multidimensional.

A partir del modelo implementado es posible analizar la información desde diferentes perspectivas:

- temporal;
- territorial;
- vehicular;
- perfil de los involucrados;
- condiciones del entorno.

El dashboard permite presentar indicadores generales y realizar análisis comparativos mediante gráficos y filtros.

Entre los resultados visualizados en el dashboard desarrollado se encuentran indicadores como:

- Total de siniestros graves;
- Índice de severidad;
- Tasa de mortalidad;
- análisis por macrodistrito;
- evolución temporal;
- distribución por tipo de vehículo;
- análisis según condiciones del entorno.

Estos resultados permiten transformar los datos operacionales en información que puede ser utilizada como apoyo para analizar patrones y necesidades relacionadas con la prevención y atención de la siniestralidad vial.

7.2 Lecciones aprendidas

Durante el desarrollo del proyecto se identificaron diferentes aspectos importantes relacionados con la implementación de una solución de Business Intelligence.

En primer lugar, se evidenció la importancia de realizar un análisis previo de la fuente de datos. La existencia de campos con diferentes formatos y valores requiere establecer reglas de transformación antes de realizar el análisis.

También se comprobó la importancia de definir correctamente la granularidad de la tabla de hechos. Una definición incorrecta podría provocar duplicidad de registros o cálculos incorrectos de los indicadores.

Otra lección importante fue la necesidad de separar las responsabilidades entre la base operacional y el Data Mart. Mientras la primera está orientada al registro de información, el modelo dimensional está orientado principalmente a la consulta y análisis.

Finalmente, se comprobó que una visualización efectiva depende directamente de la calidad del modelo de datos. Un dashboard no puede corregir problemas estructurales existentes en las etapas anteriores del proceso.

7.3 Futuras mejoras y optimización

El proyecto puede ser ampliado mediante diferentes mejoras.

Entre las principales posibilidades se encuentran:

- automatización periódica de los procesos ETL;
- incorporación de nuevos períodos históricos;
- incorporación de nuevas variables relacionadas con infraestructura vial;
- incorporación de información meteorológica externa;
- integración con fuentes geográficas;
- análisis espacial mediante mapas;
- implementación de alertas;
- incorporación de indicadores adicionales;
- optimización del rendimiento de las consultas;
- implementación de mecanismos de actualización incremental.

También podría incorporarse en futuras versiones un componente de análisis predictivo que permita estudiar tendencias y escenarios futuros. Sin embargo, esto correspondería a una etapa posterior y no forma parte del alcance principal del presente Data Mart.

8 CONCLUSIONES Y RECOMENDACIONES

8.1 Conclusiones

El desarrollo del proyecto permitió diseñar e implementar un Data Mart orientado al análisis de la siniestralidad vial en el municipio de La Paz.

La aplicación de la metodología HEFESTO permitió organizar el desarrollo en diferentes fases, comenzando con la identificación de la problemática y los requerimientos de información, continuando con el diseño del modelo dimensional y finalizando con la construcción, implantación y evaluación de la solución.

El proceso ETL desarrollado en Pentaho permitió extraer información de la fuente operacional, realizar procesos de limpieza y transformación y cargar los datos en las dimensiones y tabla de hechos del Data Mart.

El modelo dimensional implementado permite analizar la siniestralidad desde diferentes perspectivas, principalmente tiempo, ubicación, vehículo, perfil de los involucrados y condiciones del entorno.

La utilización de Power BI permitió transformar la información almacenada en el Data Mart en indicadores, gráficos y filtros interactivos, facilitando la interpretación de los datos.

En consecuencia, la solución desarrollada proporciona una base analítica para identificar patrones de siniestralidad y generar información que puede servir como apoyo a procesos de prevención, atención y planificación de recursos relacionados con la seguridad vial.

Es importante aclarar que el Data Mart constituye una herramienta de apoyo a la toma de decisiones y no realiza de manera automática la asignación de recursos. La decisión final sobre la distribución de recursos corresponde a las instancias responsables, utilizando la información analítica como uno de los elementos de apoyo.

8.2 Recomendaciones

Se recomienda mantener procesos periódicos de actualización del Data Mart para evitar que los dashboards trabajen con información desactualizada.

También se recomienda establecer reglas formales de calidad de datos para controlar valores nulos, formatos incorrectos, categorías inconsistentes y registros duplicados.

Para futuras implementaciones se recomienda automatizar la ejecución de los procesos ETL y establecer mecanismos de monitoreo que permitan detectar errores durante las cargas.

Es conveniente ampliar progresivamente las fuentes de información incorporando datos relacionados con infraestructura vial, condiciones meteorológicas, señalización, flujo vehicular y otros factores que puedan contribuir al análisis de la siniestralidad.

Asimismo, se recomienda mantener una documentación actualizada del modelo dimensional, transformaciones ETL, medidas de Power BI y procedimientos de actualización.

Finalmente, para una implementación institucional a mayor escala, se recomienda establecer mecanismos de seguridad y control de acceso, respaldos periódicos y procedimientos de mantenimiento del Data Mart.